

Séance 2.

La géographie entretient un rapport complexe avec les statistiques. Discipline longtemps centrée sur la description qualitative, elle a souvent négligé les méthodes mathématiques, malgré le fait qu'elle produise et manipule des données massives. Cette ambivalence provient de la rencontre entre la rigueur mathématique et le langage souple des sciences humaines. Pourtant, certaines branches comme l'analyse spatiale ont cherché à structurer la géographie comme une science capable de formuler des modèles, tandis que l'absence de formation mathématique dans les cursus français a contribué à maintenir une distance persistante. Aujourd'hui, aucune approche géographique ne peut se passer de méthodes statistiques, qui sont essentielles pour comprendre les phénomènes complexes dans leur dimension globale et multiscalaire.

La question du hasard occupe une place centrale. Plusieurs positions existent : le déterminisme strict, défendu par Laplace, considère que toute cause est explicable et que le hasard n'est qu'apparence ; une seconde position admet l'existence du hasard comme cause provisoirement inconnue mais potentiellement explicable grâce aux progrès futurs de la connaissance. Dans les modèles, on distingue hasard bénin et hasard sauvage. En géographie, les lois de probabilité les plus courantes sont la loi normale et la loi de Pareto, bien que d'autres puissent exister. Le document rappelle que le hasard dépend aussi de l'échelle d'observation : s'il est impossible de prévoir le comportement individuel des acteurs, il est possible de dégager des tendances globales. Le hasard est donc un outil conceptuel permettant de formuler des probabilités sur des phénomènes collectifs, sans empêcher les écarts locaux.

L'information géographique se décompose en deux grands types. Le premier concerne les caractéristiques attribuées à une unité spatiale (population, données sociales ou économiques, températures, précipitations, etc.). Ce sont les données dites *attributaires*. Le second type concerne la morphologie même des objets géographiques : formes, limites, géométrie, c'est-à-dire les données *géométriques* d'un S.I.G. L'analyse statistique concerne principalement le premier type, même si la structure spatiale peut aussi faire l'objet d'une étude quantitative.

Pour analyser les données, la géographie a besoin d'une démarche statistique en trois temps : produire ou collecter des données fiables, les décrire, puis les interpréter. La production nécessite l'usage de nomenclatures et de métadonnées permettant de définir les concepts, les lieux, les dates ou encore les méthodes d'observation. L'analyse des données repose ensuite sur les probabilités et sur les statistiques, qui permettent d'étudier la structure interne d'un jeu de données. La statistique descriptive a pour objectif de résumer les distributions observées au moyen de paramètres numériques (moyenne, médiane, variance, etc.), de graphiques ou de tableaux. Elle prépare les comparaisons et les prédictions. La statistique explicative, elle, cherche à ajuster un modèle reliant une variable à expliquer à plusieurs variables explicatives, par exemple via la régression ou l'analyse de variance.


Les visualisations mobilisées en géographie dépendent du type de variable. Pour les variables qualitatives, on utilise les diagrammes en secteurs ; pour les variables quantitatives continues, les histogrammes, les polygones de fréquence, les courbes cumulatives ou les boîtes à moustaches. Le choix dépend du type de données, du caractère qualitatif ou quantitatif et de la nécessité de représenter des distributions, des comparaisons ou des relations.

Les méthodes d'analyse de données se répartissent en trois catégories : descriptives, explicatives et prédictives. Les méthodes descriptives comprennent l'analyse factorielle en composantes principales (ACP) pour les variables quantitatives, l'analyse factorielle des correspondances (AFC) pour deux variables qualitatives et l'analyse des correspondances multiples (ACM) pour plus de deux. Elles incluent aussi les classifications, comme la classification ascendante hiérarchique (CAH). Les méthodes explicatives rassemblent notamment les régressions (simple, multiple), l'analyse discriminante, la régression logistique ou encore l'analyse de variance. Les méthodes de prévision s'appliquent aux séries chronologiques, où la valeur présente dépend des valeurs passées.

Le vocabulaire statistique est fondamental. Une *population statistique* est un ensemble d'éléments, spatiaux ou non, sur lesquels porte l'étude. L'*individu statistique* est un élément de cette population, parfois lui-même composé d'unités plus petites. Les *caractères* ou *variables statistiques* sont les caractéristiques mesurées sur chaque individu. Les *modalités* sont les valeurs prises par ces caractères ; elles doivent être exclusives et exhaustives. Les caractères peuvent être qualitatifs (nominal ou ordinal) ou quantitatifs (discret ou continu). Il n'existe pas de hiérarchie conceptuelle entre ces types, mais ils n'autorisent pas les mêmes traitements statistiques. Les variables quantitatives peuvent être discrétisées en classes, chacune définie par une amplitude (longueur de l'intervalle) et une densité (effectif divisé par l'amplitude).

Les formules de Sturges et de Yule servent à déterminer un nombre de classes adapté pour une discrétisation : ni trop élevé, ni trop faible, afin d'éviter la perte d'information. L'amplitude des classes peut alors être calculée comme l'étendue de la série divisée par ce nombre de classes.

Enfin, l'effectif correspond au nombre d'individus appartenant à une modalité donnée. La fréquence est le rapport entre l'effectif d'une modalité et l'effectif total. Les fréquences cumulées additionnent les fréquences des modalités inférieures ou égales à une valeur. L'ensemble des fréquences forme une distribution statistique empirique, indispensable pour identifier la loi de probabilité qui convient aux données et pour construire une interprétation synthétique du phénomène étudié.



### Interprétation du graphique.

La distribution du nombre d'inscrits pour une élection présidentielle présente une asymétrie très marquée à droite, ce qui est typique d'un phénomène électoral et territorial. La majorité des unités statistiques (communes, circonscriptions ou territoires selon l'échelle) regroupe un nombre relativement faible d'inscrits, tandis qu'un nombre limité d'unités concentre des effectifs très élevés, correspondant vraisemblablement aux grandes agglomérations urbaines.

La concentration des valeurs dans les classes basses traduit la structure du maillage territorial français, caractérisé par un grand nombre de petites communes et un faible nombre de grandes villes. À l'inverse, la longue traîne vers les valeurs élevées met en évidence le poids électoral disproportionné de certains territoires très peuplés, qui apparaissent comme des cas atypiques dans la distribution globale.

Dans ce contexte, la moyenne du nombre d'inscrits est peu représentative de la situation « ordinaire », car elle est fortement tirée vers le haut par ces grandes unités urbaines. La médiane, les quartiles et plus généralement les indicateurs de dispersion apparaissent donc mieux adaptés pour décrire la réalité électorale. Cette distribution justifie également l'usage d'outils graphiques comme la boîte à moustaches, afin de visualiser la dispersion et d'identifier les valeurs extrêmes.

Enfin, ce type de distribution rappelle que les données électorales ne sont pas neutres : elles reflètent des déséquilibres démographiques et territoriaux qui ont des implications politiques majeures, notamment en termes de représentation, de stratégies de campagne et de lecture des résultats électoraux.

### Séance 3.

L'étude des paramètres statistiques élémentaires repose d'abord sur la distinction entre les types de caractères. D'un point de vue général, le caractère quantitatif est plus englobant que le caractère qualitatif, car il permet non seulement de classer des individus mais aussi de mesurer des valeurs, de réaliser des opérations algébriques et d'associer des lois de probabilité. Le caractère qualitatif, lui, ne donne accès qu'à des catégories ou des modalités sans dimension métrique ; il échappe donc aux tests paramétriques et aux paramètres de dispersion évolués. Dans ce sens, le caractère quantitatif constitue une généralisation puisqu'il inclut, en plus de la description, une capacité de mesure indispensable au calcul des paramètres.

Parmi les caractères quantitatifs, on distingue les variables discrètes et les variables continues. Les premières correspondent à des valeurs isolées, souvent issues d'un comptage ( $x_n$ ), tandis que les secondes prennent leurs valeurs dans un intervalle réel. Cette distinction est essentielle car une variable continue peut être décrite par une densité et modélisée par une intégrale, alors qu'une variable discrète utilise des sommes. Elle conditionne également le choix des outils : quantiles, histogrammes, intégrales pour les continues ; effectifs et fréquences pour les discrètes.

Les paramètres de position offrent plusieurs façons de résumer une distribution. La multiplicité des moyennes (arithmétique, géométrique, harmonique, quadratique, mobile ou fonctionnelle) s'explique par leur adaptation à des contextes mathématiques différents. Par exemple, la moyenne arithmétique rend compte de la somme des valeurs, la moyenne harmonique est pertinente en présence de rapports ou de vitesses, tandis que la moyenne géométrique convient aux produits. La médiane, quant à elle, est indispensable parce qu'elle résume correctement des distributions dissymétriques et n'est pas influencée par les valeurs extrêmes. Elle découpe la population en deux parties équiprobables, ce qui en fait un indicateur robuste. Le mode ne peut être calculé que lorsque la distribution présente une valeur dominante, c'est-à-dire une modalité ou une classe possédant l'effectif ou la densité la plus élevée.

Les paramètres de concentration, tels que la médiale et l'indice de C. Gini, permettent d'apprécier la répartition interne d'une variable. La médiale partage non plus l'effectif, mais la masse totale de la variable : c'est la valeur telle que 50 % de la somme des valeurs globales lui est inférieure. L'indice de concentration, obtenu en comparant médiane et médiale, permet de mesurer si la distribution est égalitaire ou inégalitaire. Une différence forte entre les deux indique une concentration élevée ; leur proximité, au contraire, signale une faible concentration.

Les paramètres de dispersion permettent de caractériser l'hétérogénéité des données. La variance est un indicateur fondamental car elle tient compte de toutes les valeurs et mesure la dispersion autour de la moyenne via les carrés des écarts. Elle est préférable à la simple moyenne des écarts car l'utilisation des carrés offre des propriétés algébriques utiles. Toutefois, pour revenir à l'unité d'origine, on préfère parfois l'écart type, qui est la racine carrée de la variance. L'étendue est utilisée pour mesurer la dispersion à partir des valeurs extrêmes ; elle est simple mais dépend uniquement des minima et maxima, ce qui la rend moins informative lorsque la série est grande. Les quantiles — déciles, quartiles, centiles — divisent la distribution en parties égales. Ils servent à analyser la position relative d'individus ou d'ensembles. Les quartiles, en particulier, sont très utilisés car l'écart interquartile représente la dispersion centrale de 50 % des données. La boîte de dispersion (ou boîte à moustaches) permet de visualiser en un seul graphique les quartiles, la

médiane et les valeurs extrêmes. Elle facilite la comparaison entre séries et met en évidence la symétrie, les étendues locales et les valeurs atypiques.

Les paramètres de forme caractérisent la structure d'une distribution au-delà de sa simple dispersion. Les moments centrés et les moments absolus permettent d'étudier respectivement la dispersion autour de la moyenne (en tenant compte du signe ou non). Les moments centrés d'ordre 2, 3 et 4 donnent accès respectivement à la variance, à la dissymétrie et à l'aplatissement. Les moments absolus permettent quant à eux de mesurer des écarts indépendamment de la direction et sont utiles lorsque la variabilité relative importe davantage que la position. La symétrie d'une distribution est un élément essentiel à vérifier : une distribution est symétrique lorsque son moment centré d'ordre 3 est nul. Le coefficient  $\beta_1$  mesure l'asymétrie : s'il est positif, la distribution est étalée vers la droite ; s'il est négatif, vers la gauche ; s'il est nul, elle est symétrique. Le coefficient  $\beta_2$  mesure l'aplatissement : positif pour une distribution platicurtique, négatif pour une distribution leptocurtique, et nul pour une distribution mésocurtique, comme la loi normale.

En somme, l'ensemble des paramètres statistiques élémentaires — position, concentration, dispersion et forme — permet de caractériser complètement une distribution en décrivant sa valeur centrale, son étalement, sa structure interne et sa forme générale. Ils sont indispensables pour comprendre le comportement global d'une variable et pour préparer toute analyse statistique plus avancée.

#### **Voici un tableau récapitulatif des différents résultats des boîtes à moustaches obtenues :**

<b>Nom</b>	<b>Variable</b>	<b>Description</b>	<b>Interprétation</b>
boxplot_Inscrits	Inscrits	Nombre total de personnes inscrites pour voter.	Reflète la taille de l'électorat potentiel.
boxplot_Votants	Votants	Nombre total de personnes ayant participé au vote.	Indique le niveau de participation électorale.
boxplot_Abstentions	Abstentions	Distribution du nombre de personnes ne participant pas au vote.	Une médiane élevée peut indiquer un faible engagement électoral.
boxplot_Blancs	Blancs	Distribution des votes blancs.	Indicateur de mécontentement ou d'indécision parmi les votants.
boxplot_Nuls	Nuls	Distribution des votes invalides.	Peut indiquer des erreurs de vote ou des protestations.
boxplot_Exprimés	Exprimés	Distribution des votes valides.	Essentiels pour déterminer les résultats électoraux.
boxplot_Voix.1	Voix 1	Distribution des votes pour l'option ou candidat 1.	Permet de comparer les performances des différentes options.
boxplot_Voix.2	Voix 2	Distribution des votes pour l'option ou candidat 2.	Une médiane élevée indique une performance stable.
boxplot_Voix.3	Voix 3	Distribution des votes pour l'option ou candidat 3.	Un IQR réduit indique une faible dispersion des votes.

Nom	Variable	Description	Interprétation
boxplot_Voix.4	Voix 4	Distribution des votes pour l'option ou candidat 4.	Les valeurs aberrantes peuvent révéler des particularités électorales.
boxplot_Voix.5	Voix 5	Distribution des votes pour l'option ou candidat 5.	Une médiane élevée et un IQR réduit indiquent une performance stable et élevée.
boxplot_Voix.6	Voix 6	Distribution des votes pour l'option ou candidat 6.	Les valeurs aberrantes peuvent révéler des particularités électorales dans certaines régions.
boxplot_Voix.7	Voix 7	Distribution des votes pour l'option ou candidat 7.	Permet de comparer la performance des différentes options ou candidats.
boxplot_Voix.8	Voix 8	Distribution des votes pour l'option ou candidat 8.	Une médiane élevée indique un score typique élevé.
boxplot_Voix.9	Voix 9	Distribution des votes pour l'option ou candidat 9.	Un IQR réduit indique une faible dispersion des votes autour de la médiane.
boxplot_Voix.10	Voix 10	Distribution des votes pour l'option ou candidat 10.	Les valeurs aberrantes peuvent indiquer des scores inhabituels.
boxplot_Voix.11	Voix 11	Distribution des votes pour l'option ou candidat 11.	Permet d'évaluer la performance relative des candidats.
boxplot_Latitude	Latitude	Distribution des valeurs de latitude.	Peut révéler des concentrations géographiques spécifiques.
boxplot_Longitude	Longitude	Distribution des valeurs de longitude.	Une faible dispersion suggère une concentration régionale des données.
boxplot_Surface	Surface (km²)	Distribution des superficies des zones étudiées.	Une grande variabilité peut indiquer des différences significatives en termes de taille.
boxplot_Trait_de_côte	Trait de Côte (km)	Distribution des longueurs des côtes.	Pertinente pour les études géographiques ou environnementales.
boxplot_Type	Type	Distribution des catégories ou types de zones étudiées.	Une distribution variée enrichit l'analyse en offrant une vue d'ensemble des différentes catégories.

## Synthèse Globale.

Les boîtes à moustaches fournissent une représentation visuelle efficace des distributions des données électorales et géographiques. Elles permettent de mettre en évidence les tendances centrales, la dispersion, et les valeurs atypiques. Dans un contexte électoral, ces graphiques sont particulièrement utiles pour analyser les performances des candidats, la participation des électeurs, et les particularités géographiques ou démographiques des circonscriptions.

Cette analyse permet de tirer des conclusions sur les dynamiques électorales et d'identifier des zones nécessitant une attention particulière, que ce soit en termes de participation, de validité des votes, ou de performance des candidats. Pour une étude plus approfondie, il serait pertinent de croiser ces données avec des variables socio-économiques ou démographiques.

#### Séance 4.

Dans l'analyse statistique telle qu'elle est présentée dans le document, le choix entre une distribution discrète et une distribution continue dépend directement des exigences des outils mobilisés. En effet, la séance consacrée à la covariance, à la corrélation et à l'ajustement linéaire indique que ces méthodes reposent sur le traitement de variables quantitatives permettant le calcul d'espérances, de variances et de covariances. De ce fait, le critère essentiel devient la nature de l'opération mathématique requise : dès lors que l'on souhaite mesurer une covariation, établir une droite d'ajustement ou évaluer une liaison linéaire, il est nécessaire que les variables puissent être manipulées algébriquement, ce qui suppose qu'elles soient numériques. Ainsi, même si le document ne distingue pas explicitement variables discrètes et continues, il impose que les variables utilisées soient suffisamment régulières pour autoriser les calculs de covariance et de corrélation, ce qui oriente l'analyse vers des variables continues ou, à défaut, vers des variables discrètes prenant un nombre suffisamment élevé de modalités pour que l'approximation soit pertinente.

L'important n'est donc pas le type de variable en soi, mais la capacité qu'elle offre pour construire des paramètres de liaison. Une variable strictement catégorielle, même discrète, ne peut pas entrer dans le calcul d'une covariance ; en revanche, une variable discrète numérique peut être intégrée si elle permet d'évaluer l'écart à la moyenne. Dans la logique du document, le critère fondamental consiste ainsi à choisir une distribution compatible avec la covariance  $\sigma(X, Y)$ , avec la corrélation linéaire  $r$  et avec la construction d'une droite de régression. Le caractère discret ou continu n'est donc qu'un enjeu secondaire par rapport à l'exigence première : disposer de variables quantitatives mesurables.

Concernant les lois les plus utilisées en géographie, le document ne présente aucune loi de probabilité particulière : ni loi normale, ni loi log-normale, ni loi de Pareto ne sont évoquées. La séance est exclusivement consacrée au comportement conjoint de deux variables à travers leur covariation, au coefficient de Bravais-Pearson et à la régression. Ainsi, à partir de cette source seule, il est impossible d'identifier des lois statistiques privilégiées. Ce que montre en revanche le document, c'est que la géographie quantitative s'appuie fortement sur l'étude de relations linéaires, sur l'idée de variance expliquée et sur la décomposition de la variabilité d'un phénomène à partir de la covariance.

Dans ce cadre, la structure des distributions intervient uniquement à travers leur capacité à produire une dispersion mesurable autour de la moyenne et à offrir une relation suffisamment stable pour permettre l'ajustement d'un modèle linéaire. La seule nécessité implicite est que les distributions permettent la définition d'un moment d'ordre 2 (variance) et d'un moment croisé (covariance). La séance ne va pas au-delà : aucune loi n'est citée et aucune préférence disciplinaire n'est mentionnée. La géographie, telle qu'elle apparaît dans le document, se fonde donc moins sur une forme particulière de distribution que sur la possibilité de mettre en relation deux variables et de quantifier la force et le sens de leur liaison.

En somme, dans les limites strictes du document, le choix entre variables discrètes ou continues se justifie uniquement par leur compatibilité avec les outils de covariance et de corrélation, tandis que les « lois les plus utilisées » ne peuvent être identifiées, car la séance ne traite ni de lois de probabilité ni de distributions théoriques. Ce qu'elle met en lumière, en revanche, est le

rôle central que jouent les relations linéaires dans l'analyse statistique des phénomènes géographiques.

**Voici un tableau récapitulatif des différents schémas de distributions obtenus :**

Nom	Type	Description
binomiale	Binomiale	Représente une distribution discrète avec des valeurs concentrées à certains points.
chi2	Khi-deux	Montre une distribution asymétrique positive, souvent utilisée en tests statistiques.
dirac	Dirac (discrète en 0)	Distribution discrète avec une seule valeur non nulle à zéro.
lognormale	Log-normale	Distribution asymétrique positive, souvent utilisée pour modéliser des données strictement positives.
normale	Normale	Distribution symétrique en forme de cloche, centrée autour de la moyenne.
pareto	Pareto	Distribution asymétrique positive, souvent utilisée pour modéliser les revenus ou d'autres phénomènes avec une 'queue épaisse'.
poisson	Poisson	Distribution discrète souvent utilisée pour modéliser le nombre d'événements survenant dans un intervalle de temps fixe.
uniforme_continue	Uniforme continue	Distribution où toutes les valeurs dans un intervalle ont la même probabilité.
uniforme_discrète	Uniforme discrète	Distribution discrète où toutes les valeurs dans un ensemble fini ont la même probabilité.
zipf	Zipf	Distribution discrète où quelques événements sont très fréquents et beaucoup sont rares.

**Analyse des graphiques et des résultats obtenus.**

1. Loi Binomiale

Graphique : Le graphique montre une distribution discrète avec des pics à certaines valeurs.

Commentaire : La loi binomiale modélise le nombre de succès dans une série d'essais indépendants avec une probabilité de succès constante. Les pics indiquent les valeurs les plus probables de succès.

2. Loi du Khi-deux (Chi2)

Graphique : Courbe asymétrique positive, décroissante vers la droite.

Commentaire : La loi du Khi-deux est utilisée principalement dans les tests d'hypothèses et l'estimation de la variance. Elle est souvent employée pour tester l'adéquation entre des distributions observées et théoriques.

3. Loi de Dirac (discrète en 0)

Graphique : Une seule valeur non nulle à zéro.



Commentaire : La loi de Dirac est une distribution discrète qui attribue une probabilité de 1 à une seule valeur (ici, 0). Elle est utile pour modéliser des événements certains.

#### 4. Loi Log-normale

Graphique : Courbe asymétrique positive, avec une longue queue vers la droite.

Commentaire : La loi log-normale est utilisée pour modéliser des données strictement positives, comme les revenus ou les tailles de particules. Elle est souvent utilisée en finance et en biologie.

#### 5. Loi Normale

Graphique : Courbe symétrique en forme de cloche.

Commentaire : La loi normale est la plus courante en statistiques. Elle est utilisée pour modéliser de nombreux phénomènes naturels et sociaux, grâce à sa symétrie et sa concentration autour de la moyenne.

#### 6. Loi de Pareto

Graphique : Courbe décroissante avec une longue queue vers la droite.

Commentaire : La loi de Pareto est souvent utilisée pour modéliser les distributions de revenus ou d'autres phénomènes où une petite partie de la population possède une grande partie des ressources (principe des 80-20).

#### 7. Loi de Poisson

Graphique : Distribution discrète avec des pics à certaines valeurs.

Commentaire : La loi de Poisson modélise le nombre d'événements se produisant dans un intervalle de temps ou d'espace fixe, comme le nombre d'appels téléphoniques reçus par un standard.

#### 8. Loi Uniforme Continue

Graphique : Ligne horizontale, indiquant une probabilité constante sur un intervalle.

Commentaire : La loi uniforme continue est utilisée pour modéliser des phénomènes où chaque résultat dans un intervalle a la même probabilité, comme le tirage aléatoire d'un nombre dans un intervalle donné.

#### 9. Loi Uniforme Discrète

Graphique : Barres de même hauteur, indiquant une probabilité constante pour chaque valeur discrète.

Commentaire : La loi uniforme discrète est utilisée pour modéliser des phénomènes où chaque résultat dans un ensemble fini a la même probabilité, comme le lancer d'un dé équilibré.

#### 10. Loi de Zipf

Graphique : Quelques valeurs très élevées suivies d'une longue queue de valeurs faibles.

Commentaire : La loi de Zipf est utilisée pour modéliser des phénomènes où quelques événements sont très fréquents et beaucoup sont rares, comme la fréquence des mots dans un texte.

Synthèse globale.

Chaque distribution a des caractéristiques spécifiques qui la rendent adaptée à certains types de données ou de phénomènes. Les graphiques illustrent visuellement ces propriétés, ce qui permet de mieux comprendre leur comportement et leur utilisation dans divers contextes statistiques.

## Séance 5.

La statistique inférentielle vise à tirer des conclusions sur une population dite « population mère » à partir de l'étude d'un sous-ensemble de cette population, appelé échantillon.

L'échantillonnage correspond précisément à l'opération consistant à prélever une partie de la population mère afin d'en estimer les caractéristiques. L'étude exhaustive de l'ensemble de la population est en effet souvent impossible ou trop coûteuse, notamment lorsque la population est très grande ou difficilement accessible. L'échantillonnage permet ainsi d'obtenir des résultats fiables tout en tenant compte des contraintes pratiques. Les méthodes d'échantillonnage se divisent en méthodes aléatoires et non aléatoires. Les méthodes aléatoires reposent sur un tirage au sort, garantissant que chaque individu a la même probabilité d'être sélectionné, ce qui permet de limiter les biais. On distingue notamment le tirage avec remise et le tirage sans remise. Les méthodes non aléatoires, telles que l'échantillonnage systématique ou la méthode des quotas, cherchent à constituer un modèle réduit de la population mère en respectant certaines proportions connues. Le choix d'une méthode dépend du contexte de l'étude, de la disponibilité d'une base de sondage, du coût et du niveau de précision recherché. Un petit échantillon représentatif est toujours préférable à un grand échantillon biaisé.

Dans ce cadre, la théorie de l'estimation joue un rôle central. Un estimateur est une variable aléatoire, fonction des données observées, construite dans le but d'approcher un paramètre inconnu de la population, comme la moyenne, la variance ou une proportion. L'estimation correspond quant à elle à la valeur numérique prise par cet estimateur lorsque l'on observe un échantillon donné. Ainsi, la moyenne empirique d'un échantillon est un estimateur de la moyenne de la population, tandis que sa valeur calculée constitue une estimation. Les estimateurs sont soumis aux fluctuations d'échantillonnage, ce qui implique qu'ils varient d'un échantillon à l'autre.

Il est essentiel de distinguer l'intervalle de fluctuation de l'intervalle de confiance. L'intervalle de fluctuation suppose que la proportion théorique de la population est connue et permet de déterminer, pour un effectif donné, l'intervalle dans lequel une fréquence observée a une forte probabilité de se situer. Il s'agit donc d'un outil de décision permettant d'évaluer si une observation est compatible avec un modèle théorique. L'intervalle de confiance, au contraire, est utilisé lorsque le paramètre de la population est inconnu. Il encadre ce paramètre à partir d'une estimation issue de l'échantillon, en tenant compte de l'erreur d'estimation et d'un niveau de risque fixé.

La notion de biais est fondamentale en théorie de l'estimation. Le biais d'un estimateur correspond à la différence entre l'espérance mathématique de cet estimateur et la valeur réelle du paramètre à estimer. Un estimateur est dit sans biais lorsque cette différence est nulle. Dans le cas contraire, on parle d'erreur systématique, car l'estimateur varie autour d'une valeur différente du paramètre réel. Certains estimateurs peuvent être biaisés mais devenir asymptotiquement sans biais lorsque la taille de l'échantillon augmente.

Lorsque l'on travaille sur l'ensemble de la population, on parle de recensement ou d'enquête exhaustive. Toutefois, le document souligne qu'en pratique, la population étudiée est presque toujours considérée comme un échantillon, ce qui met en évidence les limites même des données très abondantes. Cette remarque permet de faire le lien avec la notion de données massives, dans la mesure où la taille importante des données ne supprime pas nécessairement les problèmes liés à la représentativité, à l'erreur ou au biais.

Le choix d'un estimateur constitue un enjeu majeur de la statistique inférentielle. Un bon estimateur doit être sans biais, convergent et, si possible, de variance minimale. La précision d'un estimateur est mesurée par l'erreur quadratique moyenne, qui combine le biais et la variance. Il ne suffit donc pas qu'un estimateur soit sans biais : sa dispersion doit également être faible. Parmi plusieurs estimateurs possibles d'un même paramètre, on privilégiera celui qui minimise l'erreur quadratique moyenne.

Les méthodes d'estimation d'un paramètre reposent sur l'utilisation de statistiques issues de l'échantillon, comme la moyenne, la variance ou la proportion. La sélection d'une méthode d'estimation dépend de la nature de la variable étudiée, des propriétés recherchées pour l'estimateur et de l'information disponible sur la loi de la population. La recherche du meilleur estimateur peut également s'appuyer sur la notion de statistique exhaustive, qui concentre toute l'information pertinente sur le paramètre étudié, ainsi que sur l'information de Fisher et les résultats théoriques encadrant la variance minimale des estimateurs sans biais.

Les tests statistiques s'inscrivent pleinement dans la logique de la statistique inférentielle. Ils servent à prendre des décisions à partir des données, en évaluant la compatibilité entre une hypothèse portant sur la population et les observations issues d'un échantillon. Ils reposent sur la connaissance des distributions d'échantillonnage et sur la prise en compte d'un risque d'erreur fixé à l'avance. La construction d'un test nécessite la définition d'un modèle probabiliste, d'une statistique de test et d'une règle de décision.

Enfin, les critiques adressées à la statistique inférentielle trouvent leur origine dans les limites inhérentes à l'échantillonnage et à l'incertitude. Les résultats sont toujours affectés par des fluctuations d'échantillonnage, des marges d'erreur et des risques de biais. La statistique inférentielle ne fournit donc jamais de certitudes absolues, mais des estimations et des décisions probabilistes. Ces limites ne constituent toutefois pas une faiblesse en soi : elles soulignent au contraire la nécessité d'une démarche rigoureuse, consciente des hypothèses et des incertitudes, afin de produire des conclusions aussi fiables que possible.

## Séance 6.

La statistique d'ordre, également appelée statistique ordinale, constitue un champ fondamental de l'analyse statistique en géographie, en particulier en géographie humaine. Elle s'applique à des variables qualitatives ordinales, c'est-à-dire des variables catégorielles pour lesquelles il existe un ordre entre les modalités. Contrairement aux statistiques nominales, qui portent sur des catégories sans hiérarchie ni relation d'ordre, la statistique ordinale repose sur le classement des observations selon une relation croissante ou décroissante. Elle s'oppose ainsi à la statistique catégorielle nominale, dans laquelle les catégories sont simplement distinctes mais non ordonnées. En utilisant des rangs plutôt que des valeurs numériques absolues, la statistique ordinale permet de comparer des objets géographiques, des territoires ou des individus, et de matérialiser des hiérarchies spatiales, par exemple entre villes, régions ou entités géographiques. Ces hiérarchies rendent compte de dynamiques de domination, de stagnation ou de déclassement au sein des espaces étudiés.

Dans les classifications issues de la statistique d'ordre, l'ordre à privilégier est l'ordre croissant, également appelé ordre naturel. Cet ordre facilite l'interprétation des données et constitue la référence générale en statistique d'ordre. Il existe toutefois des exceptions en géographie, comme la loi rang-taille, mais le principe général demeure l'ordination croissante des observations. L'ordonnement permet notamment d'identifier les valeurs aberrantes, qu'elles soient exceptionnellement élevées ou faibles, et d'étudier des propriétés spécifiques comme la valeur maximale d'une série d'observations. Une série ordonnée se présente sous la forme d'une suite de statistiques d'ordre allant de la plus petite valeur observée à la plus grande.

La corrélation des rangs et la concordance des classements répondent à des objectifs proches mais distincts. La corrélation des rangs vise à mesurer le degré de liaison entre deux classements portant sur les mêmes objets, afin de déterminer s'ils sont indépendants, similaires ou opposés. Elle s'intéresse donc à la relation statistique entre deux variables ordinales. La concordance des classements, quant à elle, cherche à évaluer le degré d'accord global entre plusieurs classements, en mesurant dans quelle mesure les rangs attribués aux objets sont cohérents entre eux. Alors que la corrélation des rangs compare deux classements à la fois, la concordance peut être généralisée à plusieurs classements simultanément, ce qui permet d'étudier des situations plus complexes impliquant plusieurs critères.

Les tests de Spearman et de Kendall sont deux outils majeurs de la corrélation des rangs. Le test de Spearman repose sur le coefficient de corrélation des rangs noté  $r_s$ , qui est une adaptation du coefficient de corrélation classique à des données ordinales. Il s'appuie sur les différences entre les rangs attribués à chaque objet dans les deux classements comparés. Lorsque  $r_s$  vaut 1, les classements sont identiques ; lorsqu'il vaut  $-1$ , ils sont parfaitement inverses ; lorsqu'il est nul, les classements sont indépendants. Le test de Spearman suppose que les rangs soient des permutations équiprobables et qu'il n'existe pas de rangs ex æquo, sauf à appliquer une correction spécifique. Pour des effectifs suffisamment grands, la distribution de  $r_s$  peut être approchée par une loi normale, ce qui permet la construction d'intervalles de confiance.

Le test de Kendall repose sur une logique différente. Il s'appuie sur le dénombrement des paires concordantes et discordantes entre deux classements. Une paire est dite concordante lorsque l'ordre relatif des deux objets est le même dans les deux classements, et discordante lorsqu'il est inversé. Le coefficient  $\tau$  de Kendall correspond au rapport entre la différence des concordances et

discordances et leur somme totale. Comme pour Spearman,  $\tau$  varie entre  $-1$  et  $+1$ , traduisant respectivement une inversion parfaite, une indépendance ou une concordance parfaite des classements. L'un des avantages du coefficient de Kendall est sa capacité à être généralisé à plusieurs classements, ce qui conduit au coefficient  $W$  de Kendall, utilisé pour mesurer la concordance de  $p$  classements portant sur les mêmes individus.

Les coefficients de Goodman-Kruskal et de Yule sont des mesures d'association adaptées aux données ordinales ou catégorielles. Le coefficient  $\Gamma$  de Goodman-Kruskal repose également sur la comparaison entre le nombre de paires concordantes et discordantes. Il mesure le surplus relatif de concordances et s'interprète de manière similaire aux coefficients de corrélation des rangs, en variant entre  $-1$  et  $+1$ . Toutefois, il peut être nul même en l'absence d'indépendance statistique, ce qui impose une interprétation prudente. Le coefficient  $Q$  d'association de Yule constitue un cas particulier du coefficient de Goodman-Kruskal, appliqué spécifiquement aux tableaux de contingence de dimension  $2 \times 2$ . Il mesure l'intensité et le sens de l'association entre deux variables dichotomiques, en s'appuyant sur les fréquences observées. Comme  $\Gamma$ , il varie entre  $-1$  et  $+1$  et permet de qualifier une association négative, nulle ou positive parfaite.

Ainsi, la statistique d'ordre fournit un ensemble cohérent d'outils permettant de classer, comparer et analyser des variables qualitatives ordonnées. Elle joue un rôle central dans l'étude des hiérarchies spatiales et sociales, en proposant des méthodes rigoureuses pour évaluer la similarité, la concordance ou l'association entre différents classements.

### Résultats sous la forme d'un tableau.

Type de Graphique	Rang (exemples)	Surface (exemples)
Loi rang-taille (axe logarithmique)	0 à 10 (log)	-10 à 15 (log)
Loi rang-taille (échelle classique)	0 à 80000	0 à 8e7

### Explication et interprétation du tableau.

#### 1. Loi rang-taille en échelle logarithmique

Le premier graphique utilise une échelle logarithmique pour les deux axes, ce qui permet de visualiser des variations sur plusieurs ordres de grandeur. Cette approche est particulièrement utile pour analyser des distributions où les valeurs couvrent une large gamme, comme c'est souvent le cas pour les lois de puissance.

- Relation décroissante : la courbe montre une décroissance régulière, typique des phénomènes où une petite proportion d'entités concentre une grande partie de la surface totale. Cela suggère une distribution inégale, où quelques éléments ont des surfaces extrêmement grandes, tandis que la majorité des entités ont des surfaces bien plus réduites.
- Valeurs extrêmes : les valeurs de surface sont étendues, ce qui indique une disparité considérable entre les entités les plus petites et les plus grandes. Les valeurs aberrantes visibles dans la boîte à moustaches précédente trouvent ici une explication : certaines surfaces sont disproportionnellement grandes par rapport à la moyenne.

Cette représentation logarithmique est essentielle pour identifier des tendances générales et des relations de puissance, souvent observées dans des contextes géographiques, économiques ou sociaux.

## 2. Loi rang-taille en échelle classique

Le deuxième graphique utilise une échelle linéaire pour les deux axes, ce qui offre une vision plus intuitive des valeurs absolues, mais peut masquer les détails des entités de petite taille.

- Concentration extrême : La courbe montre une surface exceptionnellement élevée pour le premier rang (environ 80 millions de km<sup>2</sup>), suivie d'une chute brutale vers des valeurs proches de zéro pour les rangs suivants. Cela indique une domination écrasante d'une seule entité, tandis que les autres ont des surfaces négligeables.
- Limites de l'échelle linéaire : Cette représentation ne permet pas de distinguer les variations entre les entités de petite taille, car elles sont compressées près de l'axe des abscisses. Elle met cependant en évidence l'asymétrie extrême de la distribution, où une seule entité capte une part disproportionnée de la surface totale.

### Synthèse et interprétation

Ces deux graphiques, bien que représentant les mêmes données, offrent des perspectives complémentaires :

- L'échelle logarithmique révèle la structure sous-jacente de la distribution, en mettant en évidence la relation de puissance et la présence de valeurs extrêmes. Elle est particulièrement adaptée pour analyser des phénomènes où les tailles varient sur plusieurs ordres de grandeur.
- L'échelle classique souligne la concentration extrême de la surface au sein d'une seule entité, mais ne permet pas d'analyser finement la répartition des autres rangs.

Ensemble, ces représentations illustrent un phénomène courant dans les systèmes naturels ou sociaux : une distribution très inégale, où une minorité d'entités domine en termes de taille ou de ressources. Cela peut s'appliquer à divers contextes, tels que la répartition des superficies des pays, des villes, ou des îles, où quelques éléments captent une part disproportionnée de la surface totale.

## Les humanités numériques.

### *Introduction : définir les humanités numériques.*

Les humanités numériques désignent l'ensemble des pratiques de recherche, d'enseignement et de valorisation des savoirs qui se situent à l'intersection des sciences humaines et sociales (SHS) et des technologies numériques. Elles ne consistent pas simplement à utiliser des outils informatiques pour faire plus rapidement ce qui se faisait déjà auparavant, mais à transformer en profondeur les manières de produire, d'analyser, d'interpréter et de diffuser les connaissances. Comme le rappelle le document de cours, le numérique y est à la fois outil de recherche, instrument de communication et objet d'étude, ce qui en fait un véritable changement de paradigme .

Les humanités numériques s'inscrivent dans un contexte historique marqué par le *tournant computationnel*, c'est-à-dire l'intégration durable de la pensée informatique dans les processus intellectuels. Bases de données, algorithmes, web sémantique, intelligence artificielle et visualisation des données modifient non seulement les méthodes, mais aussi les questions de recherche elles-mêmes. Les exercices Python réalisés dans ce cadre pédagogique illustrent concrètement cette mutation : ils montrent comment le code devient un langage intermédiaire entre données et interprétation.

Dans cette réflexion, on montrera d'abord en quoi les humanités numériques constituent une évolution majeure des sciences humaines (I), puis comment la pratique du code — à travers les exercices Python — révèle les enjeux de cette évolution (II), avant d'analyser les risques, limites et responsabilités critiques qui en découlent pour le chercheur (III).

### *I. Les humanités numériques comme transformation des pratiques de recherche en SHS*

Le document insiste sur le fait que les humanités numériques ne naissent pas ex nihilo, mais prolongent une histoire ancienne des relations entre humanités et informatique, depuis les métadonnées et les bases de données jusqu'au web sémantique et aux intelligences artificielles . Ce passage marque le déplacement d'une informatique perçue comme simple outil de calcul vers un système de mise en relation des savoirs, fondé sur l'hypertexte, la modélisation et la circulation de l'information.

Cette évolution modifie profondément les pratiques scientifiques. La recherche n'est plus seulement fondée sur l'accès à des sources rares ou localisées, mais sur la capacité à interroger, structurer et analyser de vastes ensembles de données hétérogènes : textes, images, cartes, flux numériques, réseaux sociaux. Les humanités numériques permettent ainsi une accélération des processus de vérification, de comparaison et de diffusion, tout en favorisant des formes nouvelles de collaboration scientifique (open data, open access, science ouverte).

Cependant, comme le souligne le document, cette transformation ne signifie pas la disparition des disciplines ni de leurs méthodes spécifiques. Les humanités numériques constituent plutôt une zone d'échange transdisciplinaire, un « big tent », où coexistent des approches variées issues de l'histoire, de la géographie, de la sociologie, de la linguistique ou encore du droit. Leur unité ne repose pas sur un objet unique, mais sur un ensemble de pratiques et de questionnements communs autour du numérique.



## *II. Le code et les exercices Python : les humanités numériques du quotidien.*

Les exercices Python réalisés illustrent de manière concrète ce que signifie faire des humanités numériques au quotidien. Manipuler un tableau de données, nettoyer un corpus, calculer des statistiques ou produire une visualisation ne relève pas d'une opération purement technique. Chaque étape implique des choix méthodologiques explicites : quelles données conserver, lesquelles exclure, comment les catégoriser, quelle métrique privilégier, quelle forme graphique adopter.

Ainsi, le code devient un lieu de formalisation de la pensée. Programmer, c'est traduire une question de recherche en une suite d'instructions logiques. Cette traduction oblige le chercheur à clarifier ses hypothèses, à expliciter ses critères et à rendre ses méthodes reproductibles. De ce point de vue, les humanités numériques renforcent la rigueur scientifique, comme le souligne le document, tout en rendant les processus de recherche plus transparents.

## *III. Limites, risques et responsabilités critiques des humanités numériques.*

Le document insiste fortement sur les risques associés aux humanités numériques, et les exercices pratiques permettent d'en prendre conscience. Le premier risque est celui de l'illusion scientifique : la précision des chiffres, la sophistication des algorithmes et l'esthétique des visualisations peuvent donner l'impression que les résultats sont objectivement vrais. Or, toute donnée est construite, située et dépendante de son contexte de production .

Un autre danger réside dans la priorisation du traitement des données au détriment de leur interprétation. Passer beaucoup de temps à coder, à optimiser un script ou à multiplier les analyses peut conduire à perdre de vue les enjeux théoriques et critiques. Le document rappelle à juste titre que les humanités numériques ne doivent pas aboutir à une « physique sociale », où les faits humains seraient réduits à des équations.

Enfin, les humanités numériques posent des questions éthiques majeures : délégation de l'interprétation aux logiciels, dépendance aux infrastructures techniques, marchandisation de la recherche, standardisation des pratiques scientifiques. Face à ces risques, le chercheur en humanités numériques a un triple devoir : un devoir de pratique (maîtriser les outils), un devoir de critique (interroger leurs effets) et un devoir de formation (transmettre une culture numérique réflexive) .

## *Conclusion*

À la lumière du document et des exercices, les humanités numériques apparaissent moins comme une discipline autonome que comme une manière renouvelée de faire des sciences humaines. Elles ne remplacent ni l'interprétation, ni l'esprit critique, ni l'analyse qualitative ; elles les mettent à l'épreuve d'un environnement computationnel qui oblige à expliciter, formaliser et partager les savoirs.

En ce sens, les humanités numériques participent à l'invention possible d'un nouvel humanisme, non pas fondé sur la toute-puissance de la technique, mais sur une articulation exigeante entre calcul et sens, automatisation et responsabilité humaine. Leur véritable enjeu n'est pas de savoir jusqu'où les machines peuvent aller, mais de comprendre comment le numérique transforme notre manière de penser, de produire du savoir et de comprendre le monde.

## Recul réflexif.

L'apprentissage de Python dans le cadre des humanités numériques a été une expérience à la fois enrichissante et exigeante. Voici ce que cette pratique m'a apporté, malgré les défis rencontrés :

1. **Une formalisation rigoureuse de la pensée.** Python m'a appris à décomposer un problème complexe en étapes logiques et exécutables. En sciences humaines, où les questions sont souvent ouvertes et qualitatives, cette rigueur est précieuse : elle oblige à clarifier ses hypothèses, à définir des variables mesurables, et à structurer son raisonnement. Par exemple, transformer une question comme *"Comment varie la participation électorale selon la taille des communes ?"* en un script Python implique de préciser les données nécessaires, les calculs à effectuer (moyennes, médianes, écarts-types), et les visualisations adaptées (histogrammes, boîtes à moustaches).
2. **L'automatisation et la reproductibilité.** L'un des apports les plus concrets a été la capacité à automatiser des tâches répétitives. Nettoyer un jeu de données, calculer des statistiques descriptives, ou générer des graphiques pour des dizaines de communes aurait été fastidieux, voire impossible, à la main. Python a non seulement économisé un temps précieux, mais a aussi garanti que mes analyses étaient reproductibles. En sciences humaines, où les interprétations peuvent varier, cette reproductibilité renforce la crédibilité des résultats et facilite les échanges avec d'autres chercheurs.
3. **L'exploration de données complexes.** Les exercices m'ont permis de manipuler des jeux de données volumineux ou multidimensionnels, comme des tableaux électoraux ou géographiques. J'ai appris à extraire des tendances, à identifier des corrélations, ou à repérer des valeurs aberrantes. Ces compétences sont devenues essentielles pour comprendre des phénomènes sociaux ou spatiaux dans leur globalité.
4. **Un pont entre disciplines.** Python est un langage polyvalent, utilisé en statistiques, en géographie, en linguistique, ou en sociologie. Les exercices m'ont montré comment le code pouvait servir de pont entre les disciplines, en intégrant des méthodes quantitatives dans des analyses qualitatives. Par exemple, croiser des données électorales avec des indicateurs socio-économiques ou géographiques ouvre des perspectives nouvelles pour étudier les inégalités territoriales ou les dynamiques politiques.
5. **Créativité et résolution de problèmes.** Contrairement à l'idée reçue, le codage n'est pas qu'une question de technique : c'est aussi un espace de créativité. Trouver une solution à un problème complexe, optimiser un script pour qu'il tourne plus vite, ou inventer une visualisation qui met en lumière un phénomène invisible dans les données brutes sont des défis intellectuellement stimulants. Python m'a appris à aborder les problèmes avec méthode, mais aussi avec imagination.

Malgré ces apports, la pratique de Python n'a pas été sans obstacles. Certaines difficultés ont été particulièrement marquantes, et je pense qu'elles sont partagées par beaucoup de débutants de ce cours.

1. **Une prise en main ardue du langage.** La syntaxe de Python, bien que réputée simple, peut sembler intimidante au début. Une virgule oubliée, une indentation mal placée, ou une parenthèse non fermée suffisent à bloquer l'exécution d'un script. Les concepts de base demandent un temps d'adaptation, surtout lorsqu'on vient des sciences humaines, où la

logique formelle est moins centrale. Exemple concret : lors de mes premiers essais, un message d'erreur comme « `SyntaxError: invalid syntax` » pouvait me laisser perplexe pendant des minutes, simplement parce que j'avais oublié un deux-points à la fin d'une ligne. Avec le temps, j'ai appris à décrypter ces messages et à les voir comme des indices plutôt que comme des échecs.

Comment j'ai progressé ?

- En pratiquant régulièrement, même sur des exercices simples.
  - En utilisant des ressources interactives comme [LearnPython](#) ou ChatGPT, qui permettent de tester du code en temps réel.
  - En relisant la documentation officielle de Python et des bibliothèques comme Pandas, qui regorgent d'exemples concrets.
2. **Mettre les résultats sous forme de tableau.** Organiser des données sous forme de tableau semble simple, mais cela devient rapidement complexe. Comment trier, agréger, ou fusionner des données sans introduire d'erreurs ? Et une fois le tableau créé, comment l'exporter dans un format exploitable (CSV, Excel) sans perdre d'informations ou altérer la mise en forme ?
  3. **Faire "parler" les résultats.** Passer d'un tableau de chiffres ou d'un graphique à une interprétation pertinente est un exercice exigeant. Il ne suffit pas de calculer une moyenne ou de tracer une courbe : il faut relier ces résultats à des questions de recherche, les contextualiser, et en tirer des conclusions significatives. En géographie ou en sociologie, les données ont une dimension spatiale, sociale ou historique qu'il faut restituer, ce qui demande du temps et de la réflexion. Exemple concret : Après avoir généré un histogramme montrant la distribution des inscrits par commune, j'ai réalisé que les chiffres bruts ne suffisaient pas. Il fallait expliquer pourquoi certaines communes sortaient du lot, quelles implications politiques cela pouvait avoir, et comment ces résultats s'articulaient avec la littérature existante. Cette étape d'interprétation a été la plus longue et la plus exigeante.
  4. **La gestion du temps.** Entre le temps passé à déboguer un script, à chercher la bonne fonction dans la documentation, ou à peaufiner une visualisation, il est facile de perdre de vue l'objectif initial : répondre à une question de recherche. J'ai souvent eu l'impression de passer plus de temps à résoudre des problèmes techniques qu'à analyser mes résultats.

### ***Mon avis général sur le codage : un outil puissant, mais exigeant.***

Au-delà des apports et des difficultés, le codage, et plus particulièrement l'utilisation de Python, représente pour moi une compétence transversale qui transforme en profondeur la manière de faire de la recherche en sciences humaines. Voici ce que j'en retiens :

1. **Un levier pour la recherche :** Python permet de traiter des volumes de données qui seraient autrement ingérables, et d'explorer des questions de recherche sous des angles nouveaux. Il ne remplace pas l'analyse qualitative, mais il la complète en offrant des perspectives quantitatives et des visualisations qui éclairent les phénomènes étudiés. Par exemple, analyser des données électorales à l'échelle nationale aurait été impossible sans outils informatiques. Python a rendu cette analyse réalisable et rigoureuse.

2. **Un défi intellectuel stimulant.** Apprendre à coder, c'est développer une nouvelle façon de penser. Cela exige de la patience, de la persévérance, et une certaine humilité face aux erreurs. Mais c'est aussi extrêmement gratifiant : chaque problème résolu, chaque script qui fonctionne, chaque visualisation qui révèle une tendance cachée est une petite victoire. Ce processus m'a appris à aborder les défis avec méthode et créativité.
3. **Une responsabilité critique.** Comme le souligne le document sur les humanités numériques, le codage n'est pas neutre. Les choix algorithmiques, les données utilisées, et les interprétations qui en découlent sont porteurs de biais potentiels. Par exemple, une mauvaise sélection de données ou une visualisation trompeuse peuvent fausser une analyse. Il est donc crucial d'adopter une approche critique, en questionnant constamment :
  - D'où viennent les données ? Sont-elles représentatives ?
  - Les méthodes utilisées sont-elles adaptées à la question posée ?
  - Quelles sont les limites des résultats obtenus ?
4. **Un investissement pour l'avenir.** Dans un monde où les données jouent un rôle croissant, maîtriser des outils comme Python est un atout majeur, que ce soit pour la recherche, l'enseignement, ou des applications professionnelles en dehors du milieu académique. C'est une compétence qui ouvre des portes et qui, une fois acquise, continue de se développer et de s'adapter à de nouveaux défis.

## **Conclusion :**

Les exercices Python m'ont apporté bien plus que des compétences techniques. Ils m'ont appris à penser de manière structurée, à aborder les problèmes avec méthode, et à intégrer des outils numériques dans une démarche de recherche critique et réflexive. Les difficultés rencontrées comme la prise en main du langage, la mise en forme des résultats, ou l'interprétation des données font partie intégrante de l'apprentissage. Elles sont largement compensées par les possibilités qu'offre le codage pour explorer, analyser, et communiquer des idées.

En définitive, le codage n'est pas une fin en soi, mais un moyen puissant pour enrichir la recherche en sciences humaines. À condition, bien sûr, de l'utiliser avec rigueur, curiosité, et esprit critique et de ne jamais perdre de vue que les données, aussi précises soient-elles, ne parlent jamais d'elles-mêmes. C'est au chercheur de leur donner sens.